

Actividad Práctica: Análisis de Reseñas de Productos con Spark SQL

Una empresa de comercio electrónico desea analizar millones de reseñas de productos publicadas por usuarios para:

- Identificar tendencias de satisfacción.
- Detectar patrones de comportamiento de los clientes.
- Comprender la distribución de calificaciones y su impacto en las ventas.

Para ello, cuenta con un dataset público en formato **Parquet**, que contiene información masiva sobre reseñas de productos de Amazon.

Dataset

https://datasets-documentation.s3.eu-west-3.amazonaws.com/amazon_reviews/amazon_reviews_2015.snappy.parquet

El dataset contiene información de reseñas de productos, incluyendo:

- Identificador de producto
- Categoría del producto
- Calificación (rating)
- Cantidad de votos útiles
- Texto de la reseña
- Indicador de compra verificada
- Fecha de la reseña

Nota: Debido al tamaño del archivo, se recomienda trabajar con subconjuntos de datos.

Consignas

Parte 1 — Carga y exploración inicial

- a. Descargar el archivo Parquet desde la URL indicada.
- b. Cargar el dataset en un DataFrame de Spark.
- c. Mostrar las primeras filas del dataset.

UADE

Ingeniería de Datos II

Actividad en clase 3/6/2026: Introducción a Apache Spark

Docentes: Mosquera – Novodvorski

- d. Analizar el esquema de datos (`printSchema()`).
- e. Identificar las columnas disponibles y su tipo de dato.

Parte 2 — Exploración general

- a. Determinar:
 - i. Cantidad total de registros.
 - ii. Cantidad de productos distintos.
 - iii. Cantidad de categorías distintas.
- b. Identificar:
 - i. Las categorías de productos más frecuentes.
 - ii. La distribución de calificaciones (`rating`).

Parte 3 — Análisis de calificaciones

- a. Calcular:
 - i. Promedio de calificación global.
 - ii. Calificación promedio por categoría.
 - iii. Cantidad de reseñas por valor de `rating` (1 a 5).
- b. Identificar:
 - i. Las categorías con mejor promedio de calificación.
 - ii. Las categorías con peor promedio de calificación.

Parte 4 — Uso de Spark SQL

- a. Crear una vista temporal del dataset.
- b. Reescribir las consultas de la Parte 3 utilizando Spark SQL.
- c. Generar una consulta que obtenga:
 - Top 10 productos con mayor cantidad de reseñas.

Parte 5 — Análisis de usuarios y comportamiento

- a. Analizar:
 - i. Cantidad de reseñas por usuario (customer_id).
 - ii. Usuarios más activos.
- b. Determinar:
 - i. Relación entre “verified_purchase” y calificación.
 - ii. Si los usuarios con compra verificada tienden a dar mejores o peores calificaciones.

Parte 6 — Análisis de votos útiles

- a. Analizar las columnas:
 - i. helpful_votes
 - ii. total_votes
- b. Calcular:
 - i. Proporción de votos útiles sobre el total.
 - ii. Reseñas más valoradas por otros usuarios.
- c. Identificar:
 - i. Top 10 reseñas con mayor cantidad de votos útiles.

Parte 7 — Optimización y Big Data

- a. Ejecutar consultas:
 - i. Con selección de todas las columnas.
 - ii. Con selección parcial de columnas.
- b. Comparar:
 - i. Tiempos de ejecución.
 - ii. Uso de recursos.
- c. Explicar conceptualmente:
 - i. ¿Cómo beneficia el formato Parquet a estas consultas?
 - ii. ¿Qué es “column pruning”?

Parte 8 — Persistencia

1. Generar un dataset agregado (por ejemplo: promedio de rating por categoría).
2. Guardar el resultado en formato Parquet.
3. Leer nuevamente el archivo generado y validar su contenido.